Avaliação Formativa Autônoma, Feedback Diagnóstico e Integridade Acadêmica: um Mapeamento de Estudos Secundários

Christopher Star Correa de Oliveira[1], Ana Liz Bomfim Gomes[1], Gustavo Alves Marçal[1], Victor Rodrigues Montebello[1]

[1]Universidade Federal de Goiás (UFG)
Goiânia – GO – Brasil

{christopherstar,bomfim,gustavomarcal,montebello}@discente.ufg.br

Abstract. *Language-model agents may assess open-ended tasks, provide feedback, and support self-regulated learning. This rapid mapping reviews 14 secondary studies (2025–2026) on assessment, feedback, self-regulation, and academic integrity, plus two formative frameworks. Following Petersen et al., we searched Google Scholar and tracked references. The evidence suggests stronger agreement with human graders for short, structured responses than for open-ended work; grading agreement alone does not ensure pedagogical quality; and integrity research prioritizes detection and policy over agent-mediated self-correction. We propose testing graduated hints, prior attempts, and conditional release of solutions for their effects on self-correction, transfer, and authorship. No pooled effects are estimated.*

Resumo. *Agentes baseados em modelos de linguagem podem avaliar tarefas abertas, oferecer feedback e apoiar a autorregulação. Este mapeamento rápido reúne 14 estudos secundários (2025–2026) sobre avaliação automatizada, feedback, autorregulação e integridade acadêmica, além de dois referenciais formativos. Seguindo Petersen et al., a busca no Google Scholar foi complementada por rastreamento de referências. Os resultados sugerem maior concordância docente em respostas curtas e estruturadas; notas semelhantes não garantem qualidade pedagógica; e a integridade acadêmica ainda enfatiza detecção e políticas, não autocorreção mediada por agentes. Propõe-se testar pistas graduais, tentativa prévia e liberação condicional de soluções quanto à autocorreção, transferência e autoria. Não foram estimados efeitos agregados.*

Palavras-chave: avaliação formativa, feedback automatizado, agentes educacionais, modelos de linguagem, integridade acadêmica, mapeamento sistemático

1. Introdução

Modelos de linguagem de grande porte (LLMs) permitem oferecer comentários individualizados sobre textos, código e outras produções. Sistemas que planejam etapas, consultam ferramentas e adaptam interações podem agir como agentes de avaliação, diagnóstico e feedback, reduzindo o tempo entre tentativa e orientação. Isso, porém, não comprova aprendizagem: comentários fluentes podem estar incorretos, ignorar a produção do estudante ou revelar a solução, substituindo o raciocínio que deveriam apoiar.

O feedback formativo informa a distância entre desempenho e meta e aponta como reduzi-la. [Hattie and Timperley, 2007] distinguem feedback sobre tarefa, processo, autorregulação e pessoa; [Nicol and Macfarlane-Dick, 2006] relacionam práticas formativas à

capacidade de monitorar a própria aprendizagem. Portanto, aproximar a nota de um agente à de um docente não basta: é preciso verificar se o diagnóstico é correto e acionável e se ajuda o estudante a revisar seu trabalho.

Em tarefas abertas, como redações, demonstrações e programas, podem existir vários caminhos válidos e critérios dependentes de contexto. A resposta pronta também pode facilitar plágio e terceirização do raciocínio. Por isso, integridade acadêmica deve integrar o desenho da interação, a transparência sobre IA e a avaliação do processo, em vez de se restringir à detecção posterior.

Este trabalho responde às seguintes perguntas:

- **RQ1.** Qual é o nível de concordância e qualidade pedagógica do feedback gerado por agentes LLM quando comparado à avaliação feita por docentes humanos?
- **RQ2.** Como os agentes são configurados para guiar o estudante no processo de autocorreção sem incentivar plágio ou terceirização completa do pensamento?

Propõe-se ainda a questão original **RQ3.** Em tarefas abertas, como pistas graduais, exigência de tentativa e justificativa prévias ou liberação condicional de respostas afetam autocorreção, transferência tardia, agência autoral e integridade, e como avaliar esses efeitos? Trata-se de uma agenda derivada de lacunas nas sínteses, não de resultado experimental.

O objetivo é comparar o que as sínteses recentes medem e identificar lacunas para estudos primários. Segue-se a lógica de mapeamento de [Petersen et al., 2008], adaptada a estudos secundários recentes e interdisciplinares.

2. Fundamentação

2.1. Avaliação, concordância e qualidade pedagógica

Uma nota próxima à de um docente representa apenas uma dimensão de validade. Estudos de avaliação automatizada frequentemente reportam correlação, coeficiente kappa ponderado (QWK), coeficiente de correlação intraclasse (ICC) ou acurácia de classificação. Essas medidas resumem concordância sob pressupostos diferentes e não demonstram que o agente identificou o equívoco conceitual correto nem que seu comentário ajudou a superá-lo. Um modelo também pode reproduzir um escore humano enviesado, ser consistente sem ser pedagogicamente útil ou oferecer uma justificativa plausível para uma pontuação errada.

Em consequência, este mapeamento trata separadamente (i) concordância de pontuação, (ii) validade e especificidade do diagnóstico, (iii) utilidade percebida e acionabilidade do comentário, e (iv) efeito na aprendizagem e na revisão. Tal distinção é compatível com a literatura de feedback formativo: a informação precisa chegar ao nível em que o estudante pode agir e monitorar a resposta à orientação [Hattie and Timperley, 2007, Nicol and Macfarlane-Dick, 2006]. Quando a revisão mede apenas satisfação ou intenção de uso, não é possível concluir que houve aprendizagem; quando mede apenas nota final, não se sabe qual parte da interação produziu o resultado.

2.2. Autorregulação e integridade

Um agente de apoio à autorregulação deve ajudar o estudante a planejar, monitorar e refletir, sem assumir integralmente a tarefa. A revisão de [Banihashem et al., 2025] mostra que a interseção entre inteligência artificial e aprendizagem autorregulada cresceu, mas a explicitação de teorias de autorregulação e de dimensões motivacionais permanece irregular. A revisão de [Xia et al., 2026] descreve possibilidades da IA generativa nas fases de planejamento, execução e reflexão, incluindo feedback e autoavaliação, enquanto ressalta que os mecanismos e escolhas de desenho ainda requerem clarificação.

Integridade acadêmica também envolve práticas institucionais, desenho de avaliação, formação para uso responsável e transparência, além de detecção. As revisões de [Memarian and Doleck, 2026] e [Bittle and El-Gayar, 2025] registram debates sobre fraude, autoria, atribuição e usos legítimos de IA. Em sínteses mais amplas, estratégias de detecção e orientação institucional recebem atenção maior que experimentos que acompanhem autoria, processo de revisão e transferência. Assim, a pergunta útil não é somente se o sistema consegue reconhecer texto gerado, mas se sua interação favorece produção intelectual observável e permite que o estudante explique e sustente suas decisões.

3. Método

3.1. Desenho e fontes

Adotou-se um mapeamento rápido de estudos secundários, orientado pelo fluxo metodológico de [Petersen et al., 2008]: delimitação das perguntas, busca, seleção, classificação e síntese descritiva. A busca foi executada em 1º de outubro de 2026 no Google Scholar, seguida de rastreamento de referências e verificação nas páginas de periódicos ou editoras. O Google Scholar foi escolhido para localizar revisões interdisciplinares entre educação, computação e integridade acadêmica; não se afirma cobertura exaustiva de bases bibliográficas.

As consultas exploratórias em inglês combinaram expressões como: `"large language model"formative assessment feedback systematic review meta-analysis 2025 2026; agentic autonomous agents formative feedback academic integrity education systematic review 2025 2026;` e `"academic integrity"generative AI assessment systematic review higher education 2025 2026.` O rastreamento de referências foi empregado para recuperar sínteses pertinentes que não aparecessem nas primeiras páginas de resultados. Como os resultados do Google Scholar variam por data, localização e perfil, a estratégia deve ser lida como busca rastreável em termos e data, mas não como uma revisão sistemática exaustiva.

3.2. Critérios e processo de seleção

Foram considerados elegíveis trabalhos publicados em 2025 ou 2026 que: (a) fossem revisão sistemática, mapeamento sistemático, revisão de escopo, meta-análise ou revisão qualitativa estruturada; (b) sintetizassem estudos empíricos sobre avaliação

automatizada, feedback educacional, autorregulação apoiada por IA ou integridade acadêmica em contexto educacional; e (c) apresentassem método e corpus identificáveis em resumo, texto ou página editorial. Incluímos uma revisão de educação em programação por sua pertinência a uma modalidade de tarefa complexa e aberta. Foram excluídos estudos primários, editoriais/opiniões sem síntese de evidências e revisões de IA sem relação educacional substantiva. Duas obras clássicas foram adicionadas apenas como base conceitual de feedback formativo; elas não integram a contagem do corpus recente.

A triagem foi feita por leitura de título, resumo e informação metodológica disponível, com consulta ao texto integral quando acessível. O processo resultou em 14 estudos secundários focais. Não registramos números de resultados brutos, duplicatas ou exclusões em cada etapa; portanto, não construímos um fluxograma PRISMA nem reivindicamos completude. A seleção foi realizada por um único pesquisador, o que aumenta o risco de omissão e classificação subjetiva.

3.3. Extração e síntese

Para cada revisão foram anotados: foco temático, tamanho e período do corpus quando reportados, modalidade de síntese, achados que respondem às RQs, limitações explicitadas e relação com agentes autônomos. Classificamos os estudos em quatro eixos: avaliação/concordância; feedback e resultados de aprendizagem; autorregulação e agentes; e integridade acadêmica. A síntese é narrativa e comparativa. Não combinamos tamanhos de efeito entre contextos, pois os estudos secundários variam quanto a tecnologias, tarefas, populações, resultados e critérios de inclusão. Tampouco reinterpretamos resultados primários que as revisões não reportaram.

4. Resultados

4.1. Caracterização do corpus

O corpus reúne 14 sínteses recentes de escopo e métodos diversos. Algumas avaliam especificamente LLMs; outras agregam ferramentas de IA anteriores ou aplicações de IA em geral. As conclusões, portanto, não devem ser tratadas como estimativa única para agentes autônomos baseados em LLM. A Tabela 1 resume o foco e a contribuição de cada eixo do corpus.

Tabela 1: Sínteses secundárias incluídas e sua contribuição ao mapeamento

Síntese	Foco	Corpus reportado	Contribuição relevante
Ba et al. (2025)	Feedback assistido por IA	129 artigos, 2014–2023	Organiza feedback por tarefa, processo, autorregulação e pessoa; aponta opacidade de relatos de modelos e resultados de aprendizagem heterogêneos.
Emirtekin (2025)	Avaliação automatizada por LLM	49 estudos, 2018–2024	Compara tarefas e métricas de avaliação; documenta variação de concordância e limitações em tarefas complexas.

Tabela 1: Sínteses secundárias incluídas e sua contribuição ao mapeamento (continuação)

Síntese	Foco	Corpus reportado	Contribuição relevante
Jukiewicz e Wyrwa (2026)	Correção e feedback por LLM	42 estudos empíricos, 2023–2025	Contrasta casos de desempenho humano e de GenAI; discute papéis de corretor, gerador e coavaliador e qualidade dos comentários.
Kaliisa et al. (2026)	IA versus feedback humano	41 estudos, 4.813 estudantes	Meta-análise de desempenho e percepção sem diferença estatisticamente significativa; reúne tipos de IA e apresenta heterogeneidade.
Lipnevich et al. (2026)	Feedback orientado por IA	104 estudos, 2008–2024	Mapeia desenhos experimentais e aponta que estudos que relacionam percepção do feedback a desempenho ainda são poucos.
Jiao e Wang (2026)	Feedback de LLM em escrita	34 estudos, 2022–fev. 2026	Sintetiza intervenções de escrita; destaca produtividade e precisão linguística, com vantagem humana em argumentação e orientação contextual.
Liu e Liang (2026)	Feedback em escrita L2	19 estudos, 66 efeitos	Estima efeitos positivos modestos, sobretudo em resultados emocionais; ressalta heterogeneidade e escopo linguístico específico.
Maier et al. (2026)	Feedback formativo por LLM	47 estudos empíricos, 2022–2026	Revisão qualitativa recente; registra ganhos condicionais ao desenho do prompt e persistência de alucinações e erros de classificação.
Banihashem et al. (2025)	IA e autorregulação	84 estudos	Mapeia contextos, teorias e fases de autorregulação; identifica uso limitado de teorias explícitas e concentração no ensino superior.
Xia et al. (2026)	IA generativa e autorregulação	73 artigos	Organiza affordances nas fases de autorregulação e indica que os mecanismos de desenho permanecem pouco explicados.
Liu et al. (2026)	Agentes generativos na educação	33 estudos empíricos, 2022–2025	Distingue agente de ferramenta generativa e descreve funções cognitivas, autorregulatórias e afetivas.
Suzuki et al. (2025)	LLM em educação em programação	25 estudos, 2022–mai. 2025	Sintetiza benefícios e limites em programação, incluindo tarefas de ordem superior e integridade.
Memarian e Doleck (2026)	Integridade e misconduct com IA	82 estudos	Classifica prevenção, detecção, apoio à aprendizagem e desenho de avaliação; evidencia desequilíbrio entre detectar e prevenir.
Bittle e El-Gayar (2025)	GenAI e integridade no ensino superior	41 artigos, 2021–2024	Sistematiza riscos e práticas éticas; propõe agenda institucional e pedagógica.

4.2. RQ1: concordância e qualidade pedagógica

As revisões de avaliação automatizada e correção descrevem um quadro condicionado ao formato da tarefa. Em respostas delimitadas, itens curtos e rubricas explícitas, há relatos de desempenho próximo ao avaliador humano. Nas respostas discursivas extensas, produções abertas e critérios que dependem de contexto, a concordância é mais variável e a revisão de [Emirtekin, 2025] relata limitações importantes, incluindo em matemática complexa. A revisão de [Jukiewicz and Wyrwa, 2026] também encontra vantagem relativa da GenAI em tarefas estruturadas, mas resultados menos consistentes na correção aberta. Em casos sintetizados por esses autores, há tanto comparabilidade quanto desempenho inferior da GenAI; não há base para declarar um nível universal de concordância.

O resultado quantitativo mais amplo é a meta-análise de [Kaliisa et al., 2026], que reuniu 41 estudos e 4.813 estudantes e não encontrou diferença estatisticamente significativa entre feedback de IA e humano para desempenho (g=0,25; IC 95% [-0,11; 0,60]) nem para percepção do feedback (g=-0,20; IC 95% [-0,67; 0,27]). Esses intervalos incluem efeitos em direções e magnitudes distintas; ausência de significância não demonstra equivalência ou não inferioridade. Além disso, a meta-análise agrega modalidades de IA que não se restringem a LLMs ou agentes. Ela informa a comparação ampla, mas não responde isoladamente à pergunta sobre autonomia de agentes em tarefas complexas.

A qualidade pedagógica é reportada de modo menos padronizado que a pontuação. [Jukiewicz and Wyrwa, 2026] observa comentários que podem ser genéricos, prolixos, abstratos ou desalinhados à prioridade de revisão, além de casos em que rubricas, exemplos e prompts contextualizados sustentam melhor desempenho. [Maier et al., 2026] também identifica potencial para feedback comparável ao docente sob condições de desenho favoráveis, mas registra erros factuais, alucinações, excesso de positividade e classificação equivocada. Em escrita, [Jiao and Wang, 2026] distingue ganhos de produtividade e precisão linguística da qualidade mais difícil de automatizar da argumentação, interpretação contextual e orientação dialógica. Portanto, "parecido com a nota docente" e "bom para aprender" são construtos distintos.

As revisões raramente permitem isolar o efeito do componente agentivo. Muitos estudos testam uma chamada de LLM ou um sistema de feedback com prompt, e não um agente que mantém estado, planeja intervenções e adapta pistas com base nas ações do estudante. [Liu et al., 2026] enfatiza justamente a distinção entre GenAI como ferramenta e agente com planejamento, memória, uso de ferramentas ou perseguição de objetivos. Essa diferença limita a transferência direta dos resultados de correção automatizada para a avaliação formativa autônoma.

4.3. RQ2: configuração para autocorreção e integridade

As configurações de interação relatadas nas revisões podem ser agrupadas em cinco estratégias. Primeiro, rubricas, critérios explícitos e exemplos de desempenho orientam a avaliação e reduzem respostas sem referência ao objetivo. Segundo, prompts com papel definido e contexto da tarefa solicitam comentários mais específicos. A revisão de [Jukiewicz and Wyrwa, 2026] indica uso recorrente de rubricas e exemplares nos estudos avaliados; [Maier et al., 2026] descreve enriquecimento de contexto e estratégias de prompt

como condições associadas a feedback mais útil. Esses achados apontam uma associação de desenho, não uma garantia de validade.

Terceiro, o agente pode comentar o processo e os próximos passos em vez de fornecer diretamente uma solução final. Quarto, pode solicitar uma tentativa, raciocínio ou autoavaliação do estudante antes de responder, usando a produção observável como contexto de diagnóstico. Quinto, pode escalonar ajuda: pergunta de reflexão, pista conceitual, pista mais específica e, somente depois, solução ou exemplo. As três últimas estratégias são coerentes com a autorregulação descrita por [Banihashem et al., 2025, Xia et al., 2026], mas as sínteses disponíveis não comparam de modo robusto essas alternativas para demonstrar qual protege melhor a autoria ou produz transferência duradoura.

Agentes educacionais são ainda configurados em papéis como avaliador, gerador de feedback e coavaliador, com possibilidades emergentes de múltiplos agentes [Liu et al., 2026, Jukiewicz and Wyrwa, 2026, Maier et al., 2026]. A autonomia, contudo, pode criar riscos quando a sequência de ações e a base de evidências não são visíveis ao estudante ou ao docente. Recomenda-se, como implicação de desenho a ser testada, que o sistema mostre quais critérios aplicou, vincule cada diagnóstico a trechos ou etapas da produção e permita ao estudante contestar o comentário. A confiança deve resultar de justificativas verificáveis, não somente do tom assertivo.

No campo de integridade, [Memarian and Doleck, 2026] organiza intervenções que incluem ambiente institucional, detecção, suporte ao uso educacional de GenAI, educação sobre uso e redesenho de avaliação; a distribuição do corpus dá mais visibilidade a detecção que a prevenção e acompanhamento. [Bittle and El-Gayar, 2025] também enfatiza que os riscos dependem do contexto institucional e que a resposta deve incluir práticas de uso ético. A revisão de programação [Suzuki et al., 2025] acrescenta que benefícios para tarefas de código coexistem com limites em competências de ordem superior e desafios de integridade. Em conjunto, as sínteses apoiam deslocar o foco de policiamento isolado para práticas que tornem o processo de autoria observável e ensinem usos permitidos.

Uma configuração compatível com essa orientação é exigir que o estudante apresente uma tentativa ou explique sua decisão; responder primeiro com perguntas e pistas graduais; reservar a resposta completa para uma etapa posterior ou justificável; registrar a contribuição da IA; e solicitar que o estudante revise, teste ou defenda o resultado. Essa configuração sintetiza princípios de autorregulação e integridade e constitui hipótese de projeto. As revisões não demonstram que tais medidas, isoladamente ou em conjunto, eliminem plágio, nem que uma tentativa prévia seja suficiente para assegurar autoria.

4.4. RQ3: questão original e agenda de pesquisa

A lacuna mais consistente entre as sínteses é a separação dos resultados que importam para uma avaliação formativa íntegra. Revisões de correção privilegiam concordância ou acurácia; revisões de feedback e escrita frequentemente medem percepção, produto imediato ou intenção de uso; revisões de autorregulação mapeiam funções e teorias; e revisões de integridade dão maior espaço a risco, política e detecção. Poucas sintetizam evidência longitudinal sobre se a ajuda preserva a agência do estudante, melhora desempenho em uma nova tarefa sem assistência e mantém uma trilha de autoria defensável. A presença de agentes autônomos é ainda emergente no corpus identificado [Liu et al., 2026].

Assim, propõe-se investigar a RQ3 com um desenho comparativo em tarefas abertas autênticas. Um estudo poderia contrastar feedback direto com uma condição de ajuda escalonada que solicita tentativa e justificativa, oferece pistas e libera exemplos sob condições explícitas. Para evitar que uma única nota represente todos os resultados, o protocolo deveria medir: (i) concordância de pontuação com docentes por QWK ou ICC e adjudicação de casos divergentes; (ii) correção, especificidade, fundamentação e acionabilidade do diagnóstico por avaliadores cegos; (iii) qualidade e autoria das revisões feitas pelo estudante; (iv) retenção e transferência tardia em tarefa nova, sem agente; e (v) capacidade de explicar e defender as decisões, junto com declaração transparente do uso de IA. Deve-se estratificar por disciplina, complexidade, proficiência linguística e experiência prévia, registrar intervenções do agente e incluir avaliação humana para erros de alto impacto.

Essa agenda não supõe que pistas graduais sempre sejam superiores. A hipótese precisa admitir efeitos adversos: pistas podem ser vagas, impor carga adicional ou frustrar estudantes; uma resposta direta pode ser útil em momentos específicos; e um agente pode induzir dependência mesmo quando o comentário parece formativo. O resultado relevante é identificar em quais condições o apoio favorece desempenho independente e autoria, para quais estudantes e tarefas, e a que custo de tempo e supervisão.

5. Discussão

Quanto à RQ1, não há nível único de concordância de agentes LLM: a avaliação é mais previsível em tarefas estruturadas e menos estável em produções abertas. A meta-análise inclui tecnologias heterogêneas, sem comprovar equivalência geral. Como qualidade pedagógica envolve especificidade e ação, futuras avaliações devem medir separadamente concordância, utilidade do feedback e aprendizagem.

Quanto à RQ2, revisões descrevem rubricas, exemplares, prompts contextualizados e papéis de avaliação em ciclos de autorregulação. Porém, faltam evidências diretas de prevenção da terceirização do raciocínio. Pistas graduais, tentativa prévia, reflexão e divulgação do uso da IA são intervenções testáveis, não soluções validadas. Integridade exige medidas de processo e transferência, além de detectores.

O termo agente também exige precisão. Muitos estudos analisam corretores pontuais, enquanto agentes capazes de escolher etapas, manter estado, consultar ferramentas e decidir intervenções são mais recentes. Sem descrever o grau de autonomia, comparações e sínteses permanecem frágeis.

5.1. Implicações para projeto e avaliação

Para uso responsável, o agente deve relacionar comentários a critérios claros, indicar evidências da produção, reconhecer incerteza e permitir contestação. A ajuda pode ser graduada conforme as tentativas, com soluções reveladas apenas quando justificadas. Docentes devem revisar situações de maior impacto.

A avaliação deve comparar agentes com docentes e condições sem agente ou com feedback humano. Registros devem incluir modelo, prompt, rubrica, contexto, turnos e

intervenções humanas. Concordância requer intervalos e análise de divergências, enquanto aprendizagem exige observar revisões e transferência tardia. As regras de autoria e transparência devem ser apresentadas previamente, sem presumir má conduta por uso de IA.

5.2. Limitações

Por ser mapeamento rápido, o estudo não garante exaustividade. A busca no Google Scholar e a triagem por um pesquisador podem omitir trabalhos ou gerar viés. Os 14 estudos têm recortes e populações distintos, e seus corpora possivelmente se sobrepõem; portanto, não se devem somar seus tamanhos como amostras independentes.

Os dados vieram de textos e páginas editoriais, sem reanálise dos estudos primários. As revisões combinam diferentes tipos de IA, disciplinas e populações; achados sobre escrita, programação e ensino superior não se generalizam automaticamente. Buscas de outubro de 2026 incluem publicações recentes cuja indexação ainda muda.

6. Conclusão

O mapeamento de 14 sínteses indica que a concordância entre IA e docentes depende da estrutura da tarefa e que notas semelhantes não asseguram feedback pedagogicamente útil. Em tarefas abertas, persistem erros diagnósticos, comentários genéricos e dependência de contexto. Rubricas e contextualização parecem promissoras, mas faltam comparações longitudinais sobre prevenção da terceirização cognitiva.

A contribuição é formular RQ3 sobre pistas graduais, tentativa prévia e liberação condicional de soluções como meios possíveis de promover autocorreção e transferência sem prejudicar a autoria. Estudos futuros devem combinar avaliação docente, qualidade diagnóstica, revisões, desempenho tardio independente e transparência. Até lá, agentes devem apoiar, não substituir, a avaliação formativa supervisionada por docentes.

Referências

Ba, S. et al. (2025). Unraveling the mechanisms and effectiveness of ai-assisted feedback in education: A systematic literature review. *Computers and Education: Open*, 9:100284. doi: 10.1016/j.caeo.2025.100284.

Banihashem, S. K. et al. (2025). A systematic mapping review at the intersection of artificial intelligence and self-regulated learning. *International Journal of Educational Technology in Higher Education*, 22(50). doi: 10.1186/s41239-025-00548-8.

Bittle, K. and El-Gayar, O. (2025). Generative ai and academic integrity in higher education: A systematic review and research agenda. *Information*, 16(4):296. doi: 10.3390/info16040296.

Emirtekin, E. (2025). Large language model-powered automated assessment: A systematic review. *Applied Sciences*, 15(10):5683. doi: 10.3390/app15105683.

Hattie, J. and Timperley, H. (2007). The power of feedback. *Review of Educational Research*, 77(1):81–112. doi: 10.3102/003465430298487.

Jiao, H. and Wang, Y. (2026). Large language models for formative feedback in writing instruction: A systematic review of classroom interventions, feedback quality, and student outcomes. *Frontiers*

in Education, 11. doi: 10.3389/feduc.2026.1834085.

Jukiewicz, M. and Wyrwa, J. (2026). Can chatgpt replace the teacher in assessment? a review of research on the use of large language models in grading and providing feedback. *Applied Sciences*, 16(2):680. doi: 10.3390/app16020680.

Kaliisa, R., Misiejuk, K., López-Pernas, S., and Saqr, M. (2026). How does artificial intelligence compare to human feedback? a meta-analysis of performance, feedback perception, and learning dispositions. *Educational Psychology*, 46(1):80–111. doi: 10.1080/01443410.2025.2553639.

Lipnevich, A. A. et al. (2026). Mapping the landscape of ai-driven feedback in education: A scoping review. *Frontiers in Education*, 11:1799346. doi: 10.3389/feduc.2026.1799346.

Liu, X. and Liang, M. (2026). The effects of ai-assisted feedback on students' perceptions, emotions, and learning outcomes in l2 writing: A three-level meta-analysis. *System*, 139:104018. doi: 10.1016/j.system.2026.104018.

Liu, Y., Tang, X., Wu, J., Chen, L., and Wang, Y. (2026). Genai-agents in education: A systematic review of macro-level trends, educational roles, theoretical foundations and future agendas. *Interactive Learning Environments*. doi: 10.1080/10494820.2026.2672562.

Maier, U., Seibold, H., and Klotz, C. (2026). Llm-generated formative feedback in education: A qualitative systematic literature review. *Computers and Education: Open*, 10:100374. doi: 10.1016/j.caeo.2026.100374.

Memarian, B. and Doleck, T. (2026). A systematic review of academic integrity and misconduct with artificial intelligence in higher education. *SN Computer Science*, 7(49). doi: 10.1007/s42979-025-04569-y.

Nicol, D. J. and Macfarlane-Dick, D. (2006). Formative assessment and self-regulated learning: A model and seven principles of good feedback practice. *Studies in Higher Education*, 31(2):199–218. doi: 10.1080/03075070600572090.

Petersen, K., Feldt, R., Mujtaba, S., and Mattsson, M. (2008). Systematic mapping studies in software engineering. In *Proceedings of the 12th International Conference on Evaluation and Assessment in Software Engineering*, pages 68–77.

Suzuki, R., Nnadi, C., and Watanobe, Y. (2025). Systematic review of large language model applications in programming education. In *Proceedings of the 17th International Conference on Agents and Artificial Intelligence*.

Xia, Q. et al. (2026). A systematic literature review on designing self-regulated learning using generative artificial intelligence and its future research directions. *Computers & Education*, 240:105465. doi: 10.1016/j.compedu.2025.105465.